

污染比 (CR) 分析 RStudio + Windows 版

msProteomiX 多引擎蛋白质组学数据处理包 — timsTOF Pro 离子淌度-质谱 (IM-MS) 污染比分析模块
本指南面向 **Windows + RStudio** 用户。全部操作均可在 RStudio 内完成，无需命令行知识。

目录

- 1 概述
- 2 环境配置（仅需一次，约 5 分钟）
 - 2.1 安装 R + RStudio
 - 2.2 安装 msProteomiX
 - 2.3 安装 Python + alphetims
 - 2.4 验证安装
- 3 完整工作流程（分步操作）
 - 3.1 创建项目
 - 3.2 从 .d 文件提取 CR 数据
 - 3.3 交互式分组与可视化
 - 3.4 查看结果
- 4 结果解读
 - 4.1 IM-m/z 密度图
 - 4.2 CR 与 ALIF 梯度曲线
 - 4.3 跨样品对比
 - 4.4 指标鲁棒性分析
- 5 常见问题
- 6 参数参考
- 附录：CR 公式推导

1 概述

什么是 CR?

CR (Contamination Ratio, 污染比) 用于评估单细胞/微量蛋白质组学样品的清洁度。它通过测量 timsTOF Pro 数据 IM-m/z 空间中 **单电荷污染物** (聚合物、表面活性剂、化学噪声) 与 **多电荷肽段信号** 的比例来实现。

核心原理：在捕获型离子淌度 (TIMS) 中，单电荷污染物的 $1/K_0$ 值显著高于同 m/z 的多电荷肽段。利用一条分界线可将两者分开。

$CR = \Sigma I_{\text{污染}} / \Sigma I_{\text{信号}} \times 100\%$ — 数值越低越干净。




图 1: CR 分界线原理。线上方：单电荷污染物；线下方：多电荷肽段信号。

工作流程总览

全部流程在 RStudio 内完成：

步骤	内容	时间
1	创建项目并复制 .d 文件	1 分钟
2	<code>extract_cr_data()</code> 提取前体离子并计算 CR	每个文件 2-5 分钟
3	运行 <code>33_contamination_ratio.R</code> — 交互式分组 + 自动绘图	1 分钟
4	在 <code>output/</code> 查看 HTML 报告	—

2 环境配置（仅需一次）

以下步骤只需在 Windows 电脑上执行一次。

2.1 安装 R + RStudio

1 下载并安装

- R (4.3+): <https://cran.r-project.org> — 点击 "Download R x.x.x for Windows"
- RStudio: <https://posit.co/download/rstudio-desktop/> — 下载 Windows 安装包

全部使用默认设置安装即可。

2.2 安装 msProteomiX

2 打开 RStudio, 在控制台粘贴以下代码

```
# 安装 msProteomiX (一行即可)
if (!requireNamespace("remotes")) install.packages("remotes")
remotes::install_github("BayOmics/msProteomiX")

# 安装 reticulate (用于 R 调用 Python)
install.packages("reticulate")
```

```
# 预期输出:
* DONE (msProteomiX)
=== msProteomiX v0.3.0 ===
```

2.3 安装 Python + alphasims

3 方案 A: 从 RStudio 内安装 (最简单)

```
# 在 R 控制台执行:
reticulate::install_miniconda() # 自动安装 Miniconda
reticulate::py_install("alphasims") # 安装 alphasims
```

提示: 这会安装一个由 R 管理的私有 Python 环境。你不需要单独安装 Anaconda, 也不需要输入任何 Python 命令。

方案 B: 使用已有的 Anaconda

如果你电脑上已经有 Anaconda/Miniconda, 只需在 Anaconda Prompt 中安装 alphasims:

```
# 在 Anaconda Prompt 中执行 (不是 R):  
pip install alphasims
```

RStudio 的 `reticulate` 会自动检测你的 Anaconda 安装。

2.4 验证安装

4 在 R 控制台运行

```
library(msProteomiX) # 应打印版本信息  
library(reticulate)  
py_config()          # 应显示 Python 路径  
py_module_available("alphasims") # 应返回 TRUE
```

```
=== msProteomiX v0.3.0 ===  
[1] TRUE
```

如果 `py_module_available("alphasims")` 返回 `FALSE`, 请执行 `reticulate::py_install("alphasims")`, 然后重启 RStudio。

3 完整工作流程

3.1 创建项目

1 创建项目文件夹

```
library(msProteomiX)
create_project("D:/Projects/CR_Analysis")
# 这会创建:
#   D:/Projects/CR_Analysis/
#   ├── scripts/      (用户脚本, 包含 33_contamination_ratio.R)
#   ├── wkdir/        (数据目录)
#   └── output/        (结果输出)
```

2 复制 .d 文件

将 timsTOF Pro 原始数据文件夹（.d）复制到 `wkdir/` 或保留在原始位置（后续指定路径即可）。

示例目录结构：

```
D:/data/
├── HeLa_10ng_Rep1.d/
├── HeLa_10ng_Rep2.d/
├── MouseBrain_DDM_Rep1.d/
├── MouseBrain_DDM_Rep2.d/
├── MouseBrain_FFHE_Rep1.d/
└── MouseBrain_FFHE_Rep2.d/
```

3.2 从 .d 文件提取 CR 数据

3 在 R 控制台执行

```
library(msProteomiX)

# 处理某个目录下的所有 .d 文件（自动发现）
extract_cr_data(
  input_path   = "D:/data/",
  output_dir   = "wkdir/cr_output",
  n_slices     = 10,           # 每个文件取 10 个 RT 切片
  export_slices = TRUE        # 导出密度图数据
)
```

```
>>> Running extract_precursors.py ...
Input: D:/data/
Output: D:/Projects/CR_Analysis/wkdir/cr_output
Slices: 10
Python: 3.10.12
alphetims: 1.1.1
[INF0] Processing: Hela_10ng_Rep1.d
[INF0]   Loaded 2325916050 detector events
[INF0]   Slice 1/10: CR=6.4%, TIC(log2)=25.5
...
>>> Done! 6 summary file(s) in: wkdir/cr_output
```

RStudio 提示：每个 .d 文件处理需要 2–5 分钟（取决于文件大小）。控制台会显示进度信息，请勿关闭 RStudio。

3.3 交互式分组与可视化

4 打开并运行脚本

在 RStudio 中打开 `scripts/33_contamination_ratio.R`，点击右上角 **Source** 按钮。

脚本会自动执行以下操作：

1. 自动发现 `wkdir/cr_output/` 中的所有结果文件
2. 列出样品：

```
=== Step 1: Auto-discovering CR results ===
>>> Found 6 sample(s):
      [1] HeLa_10ng_Rep1
      [2] HeLa_10ng_Rep2
      [3] MouseBrain_DDM_Rep1
      [4] MouseBrain_DDM_Rep2
      [5] MouseBrain_FFHE_Rep1
      [6] MouseBrain_FFHE_Rep2
```

3. 交互式分组向导 — 按提示输入编号和组名：

```
=== Step 2: Sample grouping ===
=====
Samples to group:
-----
      [1] HeLa_10ng_Rep1      [2] HeLa_10ng_Rep2
      [3] MouseBrain_DDM_Rep1 [4] MouseBrain_DDM_Rep2
      [5] MouseBrain_FFHE_Rep1 [6] MouseBrain_FFHE_Rep2
=====
>>> 输入样品编号 (e.g. 1-2,5): 1-2
>>> 输入组名: HeLa
>>> 输入样品编号 (e.g. 1-2,5): 3-4
>>> 输入组名: DDM
>>> 输入样品编号 (e.g. 1-2,5): 5-6
>>> 输入组名: FFHE
>>> 分组完成? (y/n): y
```

4. 自动生成所有图表和 HTML 报告

灵活分组：支持任意数量的组（不限于 3 组），组名可自由定义。分组信息保存到 `cr_group_info.csv`，下次运行时自动加载。

3.4 查看结果

5 检查 output/ 文件夹

```
output/  
├─ CR_Analysis_CR_Gradient.png    ← CR vs RT 曲线  
├─ CR_Analysis_CR_TIC.png         ← 总离子流强度  
├─ CR_Analysis_CR_Heatmap_*.png   ← IM-m/z 密度图  
└─ CR_Analysis_CR_Report.html     ← 汇总 HTML 报告
```

双击 `*_CR_Report.html` 即可在浏览器中查看。

4 结果解读

4.1 IM-m/z 密度图

每张密度图展示一个 RT 切片的离子分布。**白色分界线**将污染物（上方）与肽段信号（下方）分开。每个面板标注了 CR 值。

4.1.1 HeLa 10ng（清洁参考样品）




图 2a: HeLa 10ng IM- m/z 密度图。CR 范围 6.4% (梯度中段, 最干净) 至 61.9% (梯度末端)。

4.1.2 小鼠脑组织 DDM2 (高污染)




图 2b: 小鼠脑 DDM2 密度图。CR 范围 8.2% 至 140.1%。分界线上方可见明显的污染物条带。

4.1.3 小鼠脑组织 FFHE2 (FFPE 组织)




图 2c: 小鼠脑 FFHE2 密度图。中等污染，梯度尾部富集。

4.2 CR 与 ALIF 梯度曲线

展示各样品类型污染程度随液相梯度的变化：




图 3: CR (上) 和 ALIF (下) 随梯度变化。MB DDM2 (蓝色) 全程污染偏高。

如何解读：

- U 形曲线 (HeLa)：正常 — 梯度开始/结束时肽段信号较少
- 整体偏高 (DDM2)：系统性污染 — 样品制备问题
- $CR > 100\%$ ：污染物信号超过肽段信号（严重污染）

4.3 跨样品对比

3×3 密度图矩阵




图 4：3 个样品 × 3 个 RT 切片。统一色标。MB DDM2 持续高污染。

样品水平汇总




图 5: 平均 CR 和 ALIF (含标准误差线)。

4.4 指标鲁棒性分析




图 6: 5 种光谱清洁度指标对比。CR 和 ALIF 高度相关 ($r=0.99$)，优于其他替代指标。

结论：CR 是最佳单一指标，动态范围达 10 倍。ALIF（有界 [0, 100%]）推荐作为补充指标。

5 常见问题

问题	原因	解决方法
<code>reticulate::py_config()</code> 无 Python	未安装 Python	在 R 中执行 <code>reticulate::install_miniconda()</code>
<code>py_module_available("alphatims")</code> 为 FALSE	alphatims 未安装	执行 <code>reticulate::py_install("alphatims")</code>
<code>extract_cr_data()</code> 无响应	大文件 (>10GB)	正常现象 — 请等待 5–10 分钟，查看控制台进度
CR 值全部很高 (>50%)	样品污染或分界线不当	检查样品制备；调整 <code>LINE_POINT1/2</code>
找不到密度图 CSV	提取时未导出切片	重新运行 <code>extract_cr_data()</code> ，设置 <code>export_slices = TRUE</code>
Error: CR output directory not found	路径不匹配	检查脚本中 <code>CR_DIR</code> 是否与提取时的 <code>output_dir</code> 一致
RStudio 提示“找不到函数”	未加载包	先执行 <code>library(msProteomiX)</code>

6 参数参考

`extract_cr_data()` 函数参数

参数	默认值	说明
----	-----	----

input_path	(必填)	.d 文件夹、.hdf 文件或包含它们的目录
output_dir	"wkdir/cr_output"	结果保存路径
n_slices	10	等间距 RT 切片数
export_slices	TRUE	是否导出每个切片的 CSV 文件
heatmap_rts	NULL	指定用于密度图的 RT 值（分钟），NULL = 全部
line_points	"350,0.8,950,1.3"	CR 分界线: mz1,im1,mz2,im2
python	NULL	Python 路径（自动检测）

脚本 33_contamination_ratio.R 配置

变量	默认值	说明
PROJECT_NAME	"CR_Analysis"	输出文件名前缀
CR_DIR	"wkdir/cr_output"	包含 *_cr_summary.csv 的目录
OUTPUT	"output"	图表和报告输出目录
LINE_POINT1	c(350, 0.8)	分界线端点 1: (m/z, 1/K ₀)
LINE_POINT2	c(950, 1.3)	分界线端点 2: (m/z, 1/K ₀)

附录：CR 公式推导

物理基础

在 TIMS 中， $1/K_0 \propto CCS / z$ 。在相同 m/z 下，单电荷离子 (z=1) 的 $1/K_0$ 比双电荷离子 (z=2) 高约 26%。

分界线

经过 (350, 0.8) 和 (950, 1.3) 两点

$$1/K_0 = 0.000833 \times m/z + 0.5083$$

CR 计算

- $1/K_0 \geq$ 分界线值 $\rightarrow$ 污染物 (单电荷)
- $1/K_0 <$ 分界线值 $\rightarrow$ 信号 (多电荷)

$$CR = \Sigma I_{\text{污染}} / \Sigma I_{\text{信号}} \times 100\%$$

msProteomiX v0.3.0 — BayOmics

RStudio + Windows 中文版

Generated by generate_cr_manual_rstudio_zh.py